Fluxograma das decisões do projeto de Machine Learning

Prever se um cliente volta a comprar nos 90 dias seguintes (repeat_purchase_90d). Contorno grosso: decisão ou resultado central de cada notebook.

NB1

Diagnóstico dos dados

Explorar e diagnosticar sem alterar os ficheiros originais.

1. **Estrutura e qualidade** — Tipos de variáveis, valores em falta, duplicados e incoerências lógicas.
2. **Variável-alvo** — Distribuição e desequilíbrio: cerca de 56% de compras com recompra.
3. **Relações e ruído** — Numéricas vs categóricas, redundância, ruído e possível fuga de informação.
4. **Análise temporal** — Treino vs teste: o teste é posterior, o que fundamenta a validação cronológica.
5. **Ficheiro de clientes** — Chaves únicas e integração viável; evitar informação futura ou identificadora.

NB2

Pré-processamento

Transformar os problemas do NB1 em regras reproduzíveis.

1. **Correções fixas** — Data para datetime; média histórica reconstruída; gastos anuais e intervalos impossíveis passam a nulos.
2. **Linhas utilizáveis** — Exclui 65 linhas quase vazias do treino; mantém compras com histórico incompleto e as 986 do teste.
3. **Variáveis de base** — 34 variáveis. Fora: ID, customer_id, data, alvo e random_noise; clientes.csv fica como alternativa.
4. **Divisão temporal** — 20% mais recentes para validação, com margem de 90 dias (5024 ajuste, 147 margem, 1298 validação).
5. **Receita de preparação** — Mediana + indicador de nulos, one-hot e escala, aprendidos só no treino.

NB3

Seleção de variáveis

Reduzir variáveis sem perder capacidade de previsão.

1. **Base e métrica** — Reconstrói o NB2. Métrica principal ROC-AUC; balanced accuracy como complemento.
2. **Três divisões internas** — Cronológicas, com margem de 90 dias; preparação e seleção reaprendidas em cada treino.
3. **Três abordagens** — Filter (teste F), wrapper (RFE) e embedded (L1), face à referência sem seleção.
4. **Regra de escolha** — Até 1 erro padrão abaixo da melhor AUC e menos colunas: L1 com C = 0,1.
5. **Verificação reservada** — Período reservado: AUC 0,790 com 38 de 92 colunas (0,786 com todas).

o NB4 reutiliza a preparação (NB2) e a seleção L1 (NB3)

NB4

Comparação e otimização

Escolher o algoritmo e fixar a receita final.

1. **Avaliação** — Mesma preparação e mesmas três divisões; ROC-AUC e outras métricas; Dummy com AUC 0,5.
2. **6 algoritmos × 2 seleções** — Logística, árvore, Random Forest, KNN, SVM RBF e Naive Bayes, com todas as colunas ou L1.
3. **Duas melhores famílias** — As duas com maior AUC média inicial seguem para otimização.
4. **Otimização** — Grelhas pequenas (C, max_depth, min_samples_leaf), nas mesmas divisões.
5. **Receita escolhida** — Random Forest, todas as colunas, max_depth 12, min_samples_leaf 5. AUC interna ≈ 0,78.

NB5

Ajuste final e submissão

Gerar as previsões para o Kaggle.

1. **Receita e controlo** — Carrega a receita do NB4 e confirma que reproduz a AUC guardada (≈ 0,80).
2. **Ajuste final** — Preparação, seleção e modelo reaprendidos nas 6469 compras utilizáveis.
3. **Previsões** — Probabilidades para as 986 compras do teste, mantendo ID e ordem.
4. **Validação do formato** — Mesmas colunas e ordem do sample_submission; sem nulos nem duplicados; Raw intacto.
5. **Submissão** — Guardada em data/Processed. Classes 0/1 se o sample for binário, senão probabilidades.

Explicação de cada notebook

Texto de cada etapa do projeto, na mesma ordem do fluxograma da página 1.

NB1 · Diagnóstico dos dados

O primeiro notebook tem como objetivo explorar e diagnosticar os dados, sem alterar os ficheiros originais, identificando problemas a tratar nas etapas seguintes. Inicialmente, verifica-se a estrutura e coerência dos ficheiros, os tipos de variáveis, os valores em falta, os duplicados e as inconsistências lógicas. De seguida, analisa-se a distribuição e o desequilíbrio da variável-alvo, as relações entre variáveis numéricas e categóricas, a redundância de informação e a possível presença de ruído ou fuga de informação. A análise temporal permite ainda avaliar diferenças entre treino e teste e fundamentar a estratégia de validação. Por fim, verifica-se a viabilidade da integração do ficheiro de clientes, garantindo a unicidade das chaves e evitando informação futura ou identificadora. Durante toda a análise, o conjunto de teste é utilizado apenas para comparação de distribuições, evitando a fuga de informação.

NB2 · Pré-processamento

O segundo notebook tem como objetivo converter os problemas diagnosticados no NB1 em regras de pré-processamento claras e reproduzíveis, preparando os dados para a seleção de variáveis e a modelação, sem escolher o modelo final. Inicialmente, aplicam-se correções fixas ao treino e ao teste: converte-se a data, reconstrói-se a média histórica de compras quando é verificável a relação com o gasto total e o número de compras, e tornam-se nulos os gastos anuais impossíveis e os intervalos de dias negativos, por não ser possível recuperar o valor verdadeiro. De seguida, definem-se as linhas utilizáveis: excluem-se do treino os registos praticamente vazios e sem data, conservando-se as compras com histórico incompleto e preservando todas as linhas do teste. Depois, constrói-se a tabela de variáveis, retirando os identificadores, a data absoluta e a variável de ruído, e mantendo a ficha de clientes como alternativa a comparar mais tarde. A validação é cronológica, com os 20% de compras mais recentes e uma margem de 90 dias, para que a janela do alvo do treino não alcance a validação. Por fim, a imputação, a codificação das categorias e a escala são ajustadas apenas na parte de treino, evitando fuga de informação, e aceitam categorias novas do teste.

NB3 · Seleção de variáveis

O terceiro notebook tem como objetivo perceber se é possível reduzir as variáveis preparadas no NB2 sem perder capacidade de prever uma nova compra nos 90 dias seguintes, usando a regressão logística apenas como modelo de referência. Inicialmente, reconstrói-se a base do NB2 (correções, linhas utilizáveis, variáveis de base e corte cronológico), mantendo a ficha de clientes desligada por não estar demonstrada a sua disponibilidade temporal. De seguida, define-se a estratégia de avaliação: a ROC-AUC como métrica principal, com a balanced accuracy como complemento, e três divisões cronológicas internas com margem de 90 dias, onde a imputação, a codificação, a escala e a seleção são reaprendidas em cada treino, ficando o período de validação reservado. Comparam-se então três abordagens: filter (teste F), wrapper (RFE) e embedded (regressão logística com penalização L1), com 20 ou 40 colunas e dois valores de penalização, face à referência sem seleção. O método é escolhido pela regra do erro padrão, aceitando médias até um erro padrão abaixo da melhor e optando pelo conjunto com menos colunas, o que leva ao L1 com C=0,1. Por fim, confirma-se uma única vez no período reservado que a seleção mantém o desempenho com menos colunas (38 das 92), e fixa-se o método e os seus parâmetros, e não a lista de nomes, para serem reutilizados dentro de cada treino no NB4.

NB4 · Comparação e otimização

O quarto notebook tem como objetivo comparar e otimizar modelos de classificação para prever a recompra nos 90 dias seguintes, fixando a receita final a usar no NB5. Inicialmente, reproduz-se a preparação dos NB2 e NB3 e mantém-se a mesma estratégia temporal, com três divisões cronológicas internas e margem de 90 dias, usando a ROC-AUC como métrica principal e a balanced accuracy, a precisão, o recall e o F1 como complemento, além da log loss e do Brier para a qualidade das probabilidades. De seguida, comparam-se seis algoritmos (regressão logística, árvore de decisão, Random Forest, KNN, SVM RBF e Gaussian Naive Bayes), cada um com todas as colunas e com a seleção L1 (C=0,1) reaprendida em cada treino, face a um baseline Dummy com AUC de 0,5. Depois, otimizam-se os dois melhores candidatos através de pequenas grelhas de parâmetros, avaliadas nas mesmas divisões, e escolhe-se a configuração com maior ROC-AUC média interna, a Random Forest com todas as colunas, profundidade máxima 12 e mínimo de 5 compras por folha. Por fim, a receita é verificada uma única vez no período reservado, para diagnóstico e não como avaliação independente, uma vez que já tinha sido consultado no NB3, e guarda-se a receita para o NB5 refazer a preparação e a seleção com todas as compras utilizáveis.

NB5 · Ajuste final e submissão

O quinto notebook gera a submissão para o Kaggle a partir da receita escolhida no NB4. Reconstrói a limpeza e as 34 variáveis de base e confirma a ROC-AUC no período de validação. Como a competição avalia F1, compara limiares nas três divisões temporais internas, sem usar o teste, e escolhe 0,425 nesta execução. Depois, a preparação e a Random Forest (todas as colunas, profundidade máxima 12, mínimo de 5 compras por folha) são reajustadas nas 6469 compras utilizáveis. Geram-se probabilidades para as 986 compras do teste, convertidas em classes com o limiar escolhido. Por fim, verificam-se o ID, a ordem, os vazios e os duplicados, e guarda-se o CSV em data/Processed/, sem alterar o ficheiro original.

Princípios transversais

- **Sem fuga de informação:** tudo o que é aprendido fica no treino de cada avaliação; o teste nunca ajusta nada.
- **Validação cronológica** com margem de 90 dias, porque o alvo olha 90 dias para a frente.
- **Corrigir só com base verificável;** caso contrário, marcar o valor como ausente.

Limitações assumidas

- Poucas divisões temporais, reutilizadas na procura: a AUC interna e o F1 escolhido podem ser otimistas.
- O período de validação já tinha sido consultado no NB3: é diagnóstico, não avaliação independente.
- Sem calibração; o limiar F1 usa períodos internos já consultados e a ficha de clientes não foi usada.